

Compte Rendu : Détection de Fraude aux Cartes de Crédit

Brini Mohamed Taha (22007218) **Thématique** : Économie / Finance

1. Introduction et Contexte

Dans le cadre d'un module de Machine Learning, ce projet vise à développer un système prédictif pour identifier les transactions frauduleuses en temps réel. Ce besoin répond à un enjeu économique majeur : les pertes annuelles dues à la fraude se chiffrent en milliards d'euros pour les institutions financières.

2. Analyse du Jeu de Données

Le travail repose sur le dataset Kaggle **Credit Card Fraud Detection**:

- **Volume** : 284 807 transactions européennes sur 2 jours.
- **Variables** : 28 variables anonymisées issues d'une PCA (V1 à V28), ainsi que le Time (temps) et l' Amount (montant).
- **Déséquilibre massif** : Le jeu de données ne contient que **492 fraudes** contre **284 315 transactions normales**.
- **Taux de fraude** : Environ **0,17 %**, ce qui rend les métriques classiques comme l'accuracy insuffisantes pour juger de la performance.

3. Méthodologie et Préparation des Données

Pour traiter ce déséquilibre extrême, une stratégie de preprocessing rigoureuse a été adoptée :

- **Nettoyage** : Suppression des doublons pour éviter tout biais dans l'apprentissage.
- **Feature Engineering** :
 - Création de Log_Amount pour réduire l'asymétrie de la distribution des montants.
 - Utilisation de RobustScaler pour normaliser les variables sensibles aux valeurs aberrantes.

- **Gestion du déséquilibre** : Utilisation de la technique **SMOTE** (oversampling) pour équilibrer la classe minoritaire, appliquée uniquement sur le set d'entraînement via un pipeline pour éviter les fuites d'information.
- **Validation** : Split **80 % / 20 %** avec **stratification** pour garantir que la proportion de fraude est identique dans les ensembles d'entraînement et de test.

4. Stratégie de Modélisation

Trois algorithmes ont été sélectionnés pour leur efficacité en classification binaire:

1. **Régression Logistique** (Baseline).
2. **Random Forest** (Modèle robuste basé sur les arbres).
3. **XGBoost** (Optimisé pour les performances de prédiction).

Chaque modèle est optimisé via **GridSearchCV** avec un focus sur le score **ROC-AUC**, car cette métrique est particulièrement adaptée aux déséquilibres extrêmes.

5. Résultats et Interprétations

L'analyse exploratoire (EDA) a permis d'identifier des variables clés comme V14 et V17, qui montrent des distributions très distinctes entre transactions légitimes et frauduleuses.

Métriques d'évaluation retenues :

- **Recall** : Prioritaire pour minimiser les faux négatifs (fraudes non détectées).
- **Précision** : Pour limiter les faux positifs et ne pas dégrader l'expérience client.
- **F1-Score** : Pour trouver le meilleur équilibre entre précision et rappel.

6. Conclusion et Recommandations

Ce projet démontre que la détection de fraude nécessite bien plus qu'une simple précision globale. La chaîne d'analyse mise en place (SMOTE, validation croisée, ingénierie de variables) constitue une base solide.